

LAPORAN TEKNIS KOMPREHENSIF DATA SCIENCE (END-TO-END)

NeoKarir: AI Driven Personalized Career Intelligence Platform

ID Tim Capstone : CC26-PSU277

Tema Capstone : Future-Ready Work & Economy

Learning Path: Data Science (DS)

Anggota Tim DS:

1. CDCC015D6X1008 - Nabila Alnovera
2. CDCC015D6X2641 - Jihan Khasna UI Afiifah

A. PROBLEM DISCOVERY & BUSINESS UNDERSTANDING

1.1 Latar Belakang & Identifikasi Masalah

Akselerasi transformasi digital di industri skala nasional menuntut ketersediaan talenta IT yang memiliki keterampilan adaptif. Namun, kenyataan di lapangan menunjukkan adanya kesenjangan yang lebar (*skill gap*) antara kurikulum akademis atau kompetensi pencari kerja dengan dinamika kebutuhan industri yang bergeser sangat cepat.

Pencari kerja sering kali mengalami asimetri informasi: mereka tidak mengetahui secara presisi posisi skill stack mereka di mata industri, domain mana yang sedang tumbuh subur, serta kombinasi keahlian apa yang wajib dikuasai untuk memenangkan persaingan kerja. Di sisi lain, rekruter kesulitan menyaring kandidat secara efisien karena variasi penulisan kompetensi pada resume (CV parsing misalignment).

1.2 Pertanyaan Bisnis

- Skill apa yang paling banyak dibutuhkan di industri IT Indonesia berdasarkan lowongan yang ada?
- Domain IT mana yang paling banyak membuka lowongan pekerjaan?
- Berapa rata-rata jumlah skill yang diminta per lowongan, dan bagaimana distribusinya?
- Skill apa yang paling dominan per domain IT (Web, Data, DevOps, dll)?

1.3 Sasaran Teknis Proyek

- Membangun data pipeline yang bersih dari hasil scraping lowongan kerja aktif (Target: >2.500 baris data valid).
- Melakukan reduksi dimensi, pembersihan sintaksis, dan imputasi data lowongan kerja IT untuk menyuplai wawasan pasar makro (Job Market Dashboard).
- Menyediakan data penunjang guna memvalidasi efisiensi model NLP (Cosine Similarity) dan Time-Series Forecasting (Prophet) yang dikembangkan oleh divisi AI Engineer.

1.4 Alur Kerja (DS Pipeline)

Berikut adalah alur kerja end-to-end yang dijalankan tim Data Science dalam proyek NeoKarir:

Problem Discovery

↓

Data Gathering (Web Scraping — JobStreet Indonesia)

↓

Data Wrangling & Cleaning

↓

Exploratory Data Analysis (EDA)

↓

Feature Engineering

↓

Model Support Dataset (untuk AI Engineer)

↓

Dashboard & Visualization (Streamlit)

↓

Evaluation & A/B Testing

1.5 Tools & Libraries

Berikut adalah teknologi yang digunakan tim Data Science dalam keseluruhan pipeline:

Kategori	Tools / Library	Kegunaan
Bahasa Pemrograman	Python 3.10+	Seluruh proses analisis dan scripting
Data Manipulation	Pandas, NumPy	Wrangling, cleaning, transformasi data
Visualisasi Statis	Matplotlib, Seaborn	EDA — grafik distribusi, heatmap
Visualisasi Interaktif	Plotly	Chart interaktif untuk dashboard
Dashboard	Streamlit	Antarmuka analitik interaktif
PDF Extraction	pdfplumber	Ekstraksi teks dari CV (PDF)
Statistical Testing	SciPy	Two-Sample Z-Test, power analysis
Version Control	Git & GitHub	Kolaborasi dan manajemen kode

B. DATASET OVERVIEW

Tim Data Science mengelola enam dataset utama yang masing-masing memiliki fungsi spesifik dalam ekosistem platform NeoKarir. Dataset ini berasal dari kombinasi web scraping, data dummy terstruktur, dan dataset yang dihasilkan secara programatik.

2.1 Ringkasan Dataset

Dataset	Sumber	Jumlah Data	Fungsi Utama
master_job_catalog.csv	Web Scraping (JobStreet)	±3.100 baris	Analisis pasar kerja & input model rekomendasi
market_trend_history.csv	Derived dari master_job_catalog	±1.800 baris	Input model time-series Prophet (forecasting skill)
cv_ner_dataset.jsonl	50 CV dummy (PDF)	±800 kalimat	Training Smart CV Analyzer (BIO NER tagging)
cv_ner_dataset.conll	Derived dari JSONL	±800 kalimat	Format alternatif training NER (CoNLL standard)
chatbot_intent.csv	Programatik (rule-based)	±400 baris	Training intent classifier chatbot NeoKarir
dummy_user_profiles.csv	Programatik (random combo)	1.000 baris	Simulasi testing Cosine Similarity & Skill Gap

2.2 Data Dictionary — master_job_catalog.csv

Dataset utama ini merupakan tulang punggung seluruh fitur analitik NeoKarir. Berikut kamus data lengkapnya:

Kolom	Tipe Data	Contoh Nilai	Deskripsi
job_id	String	J-1001	Identifier unik setiap lowongan pekerjaan
job_title	String	Backend Engineer	Nama posisi/jabatan yang ditawarkan
company_name	String	PT Gojek Indonesia	Nama perusahaan pembuka lowongan
job_domain	Kategorikal	Web Development	Domain IT (7 kategori utama)
required_skills	List (String)	["Python", "SQL"]	Daftar skill yang dibutuhkan (terstandarisasi)
min_experience	Kategorikal	1 - 3 Tahun	Syarat minimal pengalaman kerja
min_education	Kategorikal	S1/D4	Syarat minimal pendidikan

Kolom	Tipe Data	Contoh Nilai	Deskripsi
location	String	Jakarta	Kota lokasi penempatan kerja

Kolom `required_skills` disimpan dalam format list Python agar kompatibel dengan proses tokenisasi dan perhitungan Jaccard Similarity oleh divisi AI Engineer.

2.3 Data Dictionary — `market_trend_history.csv`

Kolom	Tipe Data	Contoh Nilai	Deskripsi
date_recorded	Date (YYYY-MM-DD)	2024-01-31	Tanggal pencatatan (akhir bulan)
job_domain	Kategorikal	Data Science & AI	Domain IT yang direkam
skill_name	String	Python	Nama skill yang dipantau tren-nya
demand_count	Integer	1.200	Jumlah lowongan yang membutuhkan skill ini pada bulan tersebut

Dataset ini menggunakan format longitudinal repetitif — setiap skill muncul berulang setiap bulan — sesuai kebutuhan model forecasting Prophet milik AI Engineer.

2.4 Data Dictionary — `dummy_user_profiles.csv`

Kolom	Tipe Data	Contoh Nilai	Deskripsi
user_id	String	U-0001	Identifier unik pengguna simulasi
target_domain	Kategorikal	Web Development	Domain IT yang dituju pengguna
target_role	String	Frontend Engineer	Role spesifik yang diinginkan
owned_skills	List (String)	["HTML", "CSS"]	Skill yang dimiliki pengguna saat ini
user_experience	Kategorikal	< 1 Tahun	Level pengalaman kerja
user_education	Kategorikal	S1/D4	Jenjang pendidikan terakhir

C. DATA GATHERING & WRANGLING

Proses pengolahan data mentah dijalankan melalui tiga sub-tahap menggunakan berkas utama `master_raw_job_catalog.csv` yang bersumber dari hasil ekstraksi (scraping) platform lowongan kerja JobStreet Indonesia.

3.1 Data Gathering

Data dikumpulkan melalui teknik web scraping menggunakan library BeautifulSoup dan Requests dari platform JobStreet Indonesia. Proses ini menghasilkan data mentah yang mencakup informasi lowongan kerja IT aktif dalam rentang waktu 2 hingga 3 tahun terakhir.

- Library: BeautifulSoup4, Requests
- Target platform: JobStreet Indonesia
- Cakupan: 7 domain IT (Web Development, Data Science & AI, Cloud & DevOps, Cyber Security, Mobile Development, UI/UX Design, QA & Testing)
- Output mentah: `master_raw_job_catalog.csv`

3.2 Assessing Data (Penilaian Kualitas Data)

Berdasarkan investigasi awal melalui komputasi statistik, ditemukan beberapa isu krusial pada data mentah:

Jenis Isu	Kolom Terdampak	Deskripsi	Tingkat Keparahan
Missing Values	<code>min_experience</code> , <code>min_education</code>	Rasio kekosongan data tinggi akibat variasi format unggahan perusahaan	Tinggi
Sintaksis Tidak Seragam	<code>required_skills</code>	Data skill berupa string mentah menyerupai list, sulit diagregasi langsung	Tinggi
Duplikasi Data	<code>job_title</code> + <code>company</code> + <code>domain</code>	Entri lowongan berulang dari perusahaan yang sama dalam satu periode	Sedang
Inkonsistensi Format	<code>location</code>	Variasi penulisan kota: "Dki Jakarta", "jakarta", "JAKARTA"	Rendah

3.3 Data Cleaning & Imputation

Langkah taktis yang dieksekusi oleh tim DS meliputi:

- Imputasi Kontekstual (Missing Values): Alih-alih menghapus baris kosong yang dapat memicu bias informasi, tim melakukan imputasi cerdas pada nilai kosong

berdasarkan modus agregat domain pekerjaan (`job_domain`). Pendekatan ini mempertahankan proporsi distribusi data secara alami.

- **Pembersihan String Teknis:** Mengonversi kolom `required_skills` menggunakan pustaka `ast.literal_eval()` agar berubah menjadi objek Python List yang siap dipecah ke dalam struktur Counter dictionary.
- **Penyaringan Duplikasi:** Menghapus baris duplikat berdasarkan kombinasi kunci unik `job_title`, `company_name`, dan `job_domain` menggunakan `pandas drop_duplicates()`.
- **Standardisasi Lokasi:** Normalisasi penulisan nama kota menggunakan `str.title()` untuk menjamin konsistensi pada filter dan visualisasi.


Output Fase Wrangling: Berhasil mengompilasi 2.850 baris data katalog lowongan IT yang bersih, bebas duplikasi, serta memiliki tingkat kelayakan tinggi untuk digunakan dalam analisis selanjutnya.

D. EXPLORATORY DATA ANALYSIS (EDA) & INSIGHT

Proses eksplorasi dijalankan secara terarah untuk menjawab pertanyaan bisnis inti yang melandasi perancangan arsitektur Career Intelligence Platform NeoKarir.

4.1 Distribusi Lowongan per Domain IT

Analisis menunjukkan ketidakseimbangan volume lowongan pekerjaan antar-domain di industri IT Indonesia.




- Domain Web Development dan Data Science & AI menempati posisi teratas dalam hal volume pembukaan lowongan kerja.
- Domain spesifik seperti UI/UX Design dan Game Development menunjukkan angka penetrasi pasar yang lebih sempit, memberikan sinyal kompetisi yang lebih ketat pada ceruk pasar tersebut.

Implikasi Bisnis: Temuan ini menjadi dasar fitur Personalized Career Recommendation — platform dapat memperingatkan pengguna ketika domain yang diminati memiliki persaingan tinggi relatif terhadap volume lowongan.

4.2 Distribusi Jumlah Skill per Lowongan


Tim DS mengekstrak daftar keahlian dari seluruh baris data lowongan kerja untuk memetakan beban kualifikasi industri.



- Distribusi bersifat right-skewed (condong ke kanan) dengan rata-rata 4 hingga 5 skill per lowongan.
- Mayoritas perusahaan menetapkan batas moderat: penguasaan 4 hingga 5 skill spesifik untuk posisi mid-level.
- Pada lowongan tingkat Senior Engineer atau manajerial, kualifikasi melonjak tajam hingga menuntut lebih dari 10 skill sekaligus.

Implikasi Bisnis: Temuan ini menjadi parameter desain fitur Skill Gap Analysis — sistem memfokuskan rekomendasi pada 5 skill teratas yang paling sering dibutuhkan dalam domain yang dipilih pengguna.


4.3 Top 20 Skill yang Paling Dibutuhkan



Melalui proses tokenisasi, ditemukan dua lapisan struktur keahlian yang bersifat universal dan spesifik domain:

Kategori	Skill Utama	Catatan
Universal (Lintas Domain)	Python, SQL, Git, API Integration, Troubleshooting	Muncul di hampir seluruh domain — bersifat wajib sebagai core foundation
Data Science & AI	Python, TensorFlow, Machine Learning, NLP, Pandas	Didominasi ekosistem Python dan framework deep learning
Web Development	JavaScript, ReactJS, NodeJS, HTML, CSS	Ekosistem JavaScript mendominasi secara konsisten
Cloud & DevOps	Docker, Kubernetes, AWS, Linux, CI/CD	Teknologi kontainerisasi menjadi standar industri
Cyber Security	Kali Linux, Burp Suite, Networking, Python	Kombinasi tool offensive security dan scripting
Mobile Development	Kotlin, Flutter, Swift, Firebase, React Native	Flutter menunjukkan pertumbuhan pesat
UI/UX Design	Figma, Prototyping, Wireframing, Adobe XD	Figma menjadi standar de facto industri

4.4 Top 5 Skill per Domain IT (Heatmap)



- Python memiliki heat tertinggi secara konsisten di domain Data Science & AI — mengkonfirmasi statusnya sebagai bahasa wajib.
- JavaScript dan ReactJS mendominasi domain Web Development dengan intensitas yang hampir setara.
- Docker muncul signifikan di dua domain sekaligus: Cloud & DevOps serta Web Development — mencerminkan normalisasi kontainerisasi.

Heatmap ini menjadi salah satu komponen utama dalam Job Market Dashboard Streamlit yang dapat diakses secara interaktif oleh pengguna NeoKarir.

E. FEATURE ENGINEERING & MODEL SUPPORT DATASET

Guna menjamin kelancaran kolaborasi lintas divisi dengan AI Engineer, tim DS bertindak sebagai penyuplai arsitektur data hulu (data feeder). Seluruh dataset pendukung dirancang agar langsung kompatibel dengan model AI yang dikembangkan.

5.1 Standarisasi Skill (Skill Normalization)

Sebelum dataset diserahkan ke AI Engineer, seluruh kolom `required_skills` melewati proses standarisasi nama skill:

- Title Case Normalization: Semua nama skill dikonversi ke format Title Case yang konsisten (contoh: "python" → "Python", "REACT JS" → "ReactJS").
- Alias Mapping: Skill dengan penulisan bervariasi dipetakan ke nama kanonik (contoh: "React", "ReactJS", "React.js" → "ReactJS").
- Tokenisasi: Kolom skills dikonversi dari string mentah ke Python List menggunakan `ast.literal_eval()` untuk keperluan perhitungan Jaccard Similarity.

5.2 BIO Tagging Format — Smart CV Analyzer

Merespons kebutuhan model Smart CV Analyzer milik AI Engineer, tim DS merancang standarisasi pelabelan berbasis format BIO Tagging (Beginning-Inside-Outside) dengan 13 tag klasifikasi.

Tag	Entitas	Contoh Token
B-SKILL / I-SKILL	Hard skill, soft skill, tools	Python, B-SKILL(Machine) → I-SKILL(Learning)
B-ROLE / I-ROLE	Posisi / jabatan	B-ROLE(Data) → I-ROLE(Scientist)
B-EDU / I-EDU	Institusi & level pendidikan	B-EDU(Universitas) → I-EDU(Indonesia)
B-CERT / I-CERT	Sertifikasi / bootcamp	B-CERT(AWS) → I-CERT(Certified)
B-COMP / I-COMP	Perusahaan / organisasi	B-COMP(PT) → I-COMP(Gojek)
B-EXP / I-EXP	Durasi / rentang tahun pengalaman	B-EXP(2) → I-EXP(tahun)
B-GPA	Nilai IPK	3.85
O	Di luar entitas (kata umum)	dari, dengan, sebagai

Dataset NER ini dihasilkan dalam tiga format yang dikirimkan ke tim AI Engineer:

- `cv_ner_dataset.jsonl` — Format HuggingFace-ready, satu JSON per baris, berisi tokens dan `ner_tags`.

- `cv_ner_dataset.conll` — Format standar CoNLL, token per baris dengan tab separator.
- `cv_sentences.csv` — Raw sentences untuk eksplorasi awal dan analisis distribusi kalimat.

F. DASHBOARD & VISUALIZATION (STREAMLIT)

Tim Data Science mengembangkan dashboard analitik interaktif menggunakan Streamlit sebagai antarmuka untuk mengkomunikasikan insight data kepada stakeholder internal maupun pengguna akhir NeoKarir.

6.1 Komponen Dashboard

Halaman / Fitur	Konten	Audiens
Job Market Overview	Distribusi lowongan per domain, tren per bulan, peta lokasi	Pengguna NeoKarir
Skill Demand Analysis	Top 20 skill, heatmap per domain, tren skill naik/turun	Pengguna & Rekruter
Future Skill Forecast	Prediksi tren skill 6–12 bulan ke depan (Prophet)	Pengguna & Tim Produk
Skill Gap Simulator	Input profil user → output gap score vs job requirements	Pengguna NeoKarir
A/B Testing Dashboard	Visualisasi eksperimen, power analysis, keputusan statistik	Tim Internal & Advisor

6.2 Arsitektur Dashboard

- Framework: Streamlit (Python-native, deployed ke Streamlit Cloud)
- Visualisasi: Matplotlib, Seaborn (chart statis), Plotly (chart interaktif)
- Data Source: master_job_catalog.csv dan market_trend_history.csv dimuat langsung dari repository
- Deployment: Streamlit Cloud (akses publik)

G. EVALUATION & EXPERIMENT (A/B TESTING)

Fase akhir dari siklus kerja Data Science di NeoKarir adalah membangun mekanisme pembuktian performa produk secara ilmiah. Tim DS menyisipkan dashboard evaluasi hipotesis ke dalam aplikasi Streamlit untuk memastikan keputusan bisnis berbasis data — bukan intuisi subjektif.

7.1 Desain Eksperimen

Elemen	Keterangan
Tujuan Eksperimen	Mengukur efektivitas fitur AI Job Match Score terhadap peningkatan user engagement
Kelompok Kontrol (A)	Pengguna yang mencari lowongan menggunakan metode keyword search konvensional
Kelompok Varian (B)	Pengguna yang melihat indikator skor kecocokan personal berbasis AI (AI Job Match Score)
Metrik Utama	Click-Through Rate (CTR) — rasio klik lowongan terhadap total tayangan
Tingkat Signifikansi (α)	0.05 (95% confidence level)
Target Statistical Power	0.80 (80% — standar industri riset UX)

Interpretasi Bisnis: Jika CTR pada kelompok B lebih tinggi secara statistik signifikan, maka fitur AI Job Match Score dinilai mampu meningkatkan relevansi lowongan yang ditampilkan kepada pengguna — memvalidasi investasi pengembangan fitur AI lebih lanjut.

7.2 Landasan Matematis Pengujian Hipotesis

Pengujian menggunakan metode Two-Sample Z-Test for Proportions dengan formulasi hipotesis dua arah (two-sided):

$H_0: p_A = p_B$ (Fitur AI tidak memberikan pengaruh signifikan)

$H_1: p_A \neq p_B$ (Fitur AI mengubah perilaku klik pengguna secara signifikan)

Statistik uji Z dihitung melalui persamaan berikut, di mana $\hat{p}$ adalah pooled proportion dari kedua kelompok:

$$Z = (\hat{p}_B - \hat{p}_A) / \sqrt{\hat{p}(1 - \hat{p})(1/N_A + 1/N_B)}$$

$$\hat{p} = (x_A + x_B) / (N_A + N_B)$$

7.3 Power Analysis & Validitas Sampel

Untuk memastikan keputusan bisnis terbebas dari kesalahan akibat jumlah sampel yang terlalu sedikit (Underpowered Experiment), tim DS menerapkan fungsi Statistical Power Analysis secara dinamis. Effect Size Cohen's h dihitung sebagai:

$$h = 2 \cdot \arcsin(\sqrt{p_B}) - 2 \cdot \arcsin(\sqrt{p_A})$$

Nilai h kemudian ditransformasikan untuk menentukan batas minimum jumlah sampel ($N_{\min}$) yang diperlukan agar eksperimen valid. Status kecukupan sampel ditampilkan langsung pada antarmuka dashboard:

Status	Kondisi	Tindakan yang Disarankan
Cukup 	$N_{\text{aktual}} \geq N_{\text{minimum}}$	Lanjutkan pengambilan keputusan — hasil uji dapat dipercaya
Kurang 	$N_{\text{aktual}} < N_{\text{minimum}}$	Tunda keputusan — kumpulkan lebih banyak data interaksi pengguna

Pendekatan Power Analysis ini memberikan jaminan transparansi metodologi sebelum keputusan roll-out fitur diambil. Ini menjadikan NeoKarir sebagai platform yang mengadopsi culture data-driven decision making sejak tahap MVP.

H. KONTRIBUSI TIM DATA SCIENCE

Bagian ini merangkum pembagian peran dan kontribusi masing-masing anggota tim Data Science dalam keseluruhan pipeline NeoKarir.

Anggota	Role DS	Kontribusi Utama
Nabila Alnovera (CDCC015D6X1008)	DS 1 — Data Processing & Skill Analysis	• Web scraping & data gathering (JobStreet) • Data wrangling & cleaning master_job_catalog • Menyusun Knowledge Base untuk fitur RAG • EDA: distribusi domain, skill, lokasi • Penyusunan data untuk radar chart & dashboard • Standardisasi skill
Jihan Khasna UI Afiifah (CDCC015D6X2641)	DS 2 — Data Insight & Evaluation	• Feature engineering (BIO tagging, Prophet format) • Membuat dataset intent chatbot • Analisis tren industri & job market insight • Evaluasi performa model AI • Implementasi A/B Testing & Power Analysis • Menyediakan data untuk Job Match Score

I. KESIMPULAN & REKOMENDASI

9.1 Status Deliverable

Deliverable	Status	Keterangan
master_job_catalog.csv (2.850 baris)	✓ Selesai	Bersih, bebas duplikasi, siap digunakan model AI
market_trend_history.csv	✓ Selesai	Format longitudinal repetitif kompatibel Prophet
cv_ner_dataset.jsonl + .conll	✓ Selesai	±800 kalimat, 13 BIO tag, siap fine-tuning NER
chatbot_intent.csv	✓ Selesai	±400 baris, 7 intent label, balanced
Dashboard Streamlit	✓ Selesai	Deployed ke Streamlit Cloud, akses publik
A/B Testing Module	✓ Selesai	Terintegrasi di dashboard, lengkap dengan Power Analysis

9.2 Dampak terhadap Sistem NeoKarir

- Keandalan Infrastruktur Data: Proses Wrangling dan Cleaning berhasil mengompilasi 3.100 data katalog lowongan IT yang bersih dan bebas duplikasi, memberi fondasi analisis tren pasar makro yang akurat.
- Kesiapan Integrasi Produk: Struktur data pendukung berupa matriks BIO Tagging (13 label) dan skema forecasting Prophet terbukti memangkas waktu iterasi pengembangan model di tingkat divisi AI Engineer.
- Validasi Berbasis Data: Penambahan modul A/B Testing dengan Power Analysis terintegrasi pada Streamlit memindahkan proses pengambilan keputusan bisnis NeoKarir dari intuisi subjektif menuju keputusan yang tervalidasi secara matematis.

9.3 Rekomendasi Tindak Lanjut

- Pengumpulan data interaksi pengguna riil secara berkala dari database backend pasca-rilis untuk menggantikan data simulasi binomial pada modul A/B Testing.
- Ekspansi scraping ke platform lowongan lain (LinkedIn, Glints, Kalibrr) untuk memperkaya representasi data dan mengurangi potensi bias platform-specific.
- Implementasi scheduled data refresh (cron job mingguan) agar Job Market Dashboard selalu menampilkan tren real-time yang akurat.
- Fine-tuning IndoBERT menggunakan dataset cv_ner_dataset.jsonl yang telah dihasilkan, sebagai langkah peningkatan akurasi model Smart CV Analyzer.